

Expected Calibration Error (↓↓↓)
Coane (MCQA)

mc_choice-ent	0.253	0.140	0.133	0.079	0.168	0.156	0.150	0.112	0.199	0.406	0.171	0.085	0.095	0.211	0.128	0.290	0.367	0.164	0.165	0.212	0.331	0.356	0.107	0.091	0.128	0.042	0.180	0.119	0.207	0.106	
mc_choice-prob	0.065	0.775	0.080	0.800	0.070	0.751	0.050	0.829	0.099	0.531	0.107	0.419	0.134	0.674	0.092	0.597	0.084	0.317	0.059	0.227	0.119	0.498	0.115	0.289	0.088	0.112	0.123	0.133	0.065	0.068	-1.000
mc_total-ent	0.248	0.215	0.227	0.213	0.149	0.118	0.168	0.128	0.347	0.198	0.307	0.164	0.222	0.117	0.201	0.087	0.314	0.531	0.130	0.278	0.412	0.188	0.214	0.061	0.184	0.115	0.253	0.214	0.135	0.104	
mc_top-1-prob	0.065	0.165	0.080	0.332	0.070	0.330	0.050	0.099	0.099	0.189	0.107	0.200	0.134	0.268	0.092	0.347	0.084	0.316	0.059	0.226	0.119	0.512	0.115	0.274	0.088	0.080	0.123	0.125	0.063	0.065	-0.950
mc_top-k-ent-5	0.191	0.136	0.087	0.295	0.127	0.494	0.121	0.063	0.137	0.235	0.115	0.327	0.069	0.344	0.100	0.482	0.280	0.186	0.118	0.173	0.252	0.537	0.074	0.339	0.097	0.145	0.139	0.090	0.166	0.102	
mc_top-k-ent-10	0.085	0.159	0.079	0.255	0.078	0.444	0.082	0.074	0.087	0.164	0.093	0.235	0.103	0.350	0.083	0.352	0.107	0.292	0.064	0.201	0.145	0.521	0.104	0.312	0.071	0.134	0.089	0.112	0.086	0.085	-0.950
mc_top-k-ent-25	0.112	0.171	0.121	0.230	0.062	0.358	0.087	0.095	0.172	0.131	0.153	0.172	0.160	0.293	0.117	0.262	0.115	0.374	0.057	0.228	0.220	0.476	0.146	0.282	0.101	0.121	0.139	0.115	0.075	0.067	
mc_top-k-ent-50	0.144	0.186	0.139	0.217	0.087	0.306	0.104	0.104	0.210	0.100	0.193	0.120	0.177	0.268	0.137	0.217	0.157	0.414	0.069	0.242	0.261	0.442	0.164	0.249	0.130	0.104	0.159	0.122	0.071	0.080	
mc_top-k-ent-100	0.164	0.201	0.168	0.218	0.094	0.257	0.123	0.108	0.244	0.074	0.218	0.110	0.191	0.236	0.156	0.190	0.185	0.440	0.075	0.251	0.300	0.402	0.184	0.224	0.136	0.088	0.184	0.136	0.080	0.070	
mc_top-p-len-0.95	0.128	0.139	0.203	0.337	0.209	0.075	0.119	0.167	0.320	0.321	0.233	0.265	0.089	0.175	0.058	0.161	0.164	0.317	0.196	0.269	0.117	0.656	0.105	0.114	0.127	0.121	0.047	0.190	0.263	0.098	
mc_top-p-len-0.9	0.047	0.150	0.120	0.147	0.143	0.197	0.057	0.158	0.190	0.394	0.151	0.294	0.095	0.199	0.057	0.166	0.071	0.379	0.122	0.271	0.041	0.329	0.077	0.154	0.053	0.111	0.086	0.192	0.148	0.103	-0.967
mc_top-p-len-0.75	0.147	0.184	0.093	0.175	0.063	0.221	0.093	0.160	0.121	0.422	0.126	0.299	0.150	0.273	0.112	0.182	0.138	0.467	0.053	0.268	0.159	0.355	0.108	0.167	0.064	0.109	0.177	0.193	0.025	0.105	-1.000
mc_top-p-len-0.5	0.237	0.214	0.168	0.197	0.098	0.231	0.125	0.160	0.274	0.424	0.215	0.300	0.161	0.283	0.146	0.186	0.288	0.547	0.082	0.256	0.357	0.358	0.170	0.169	0.103	0.110	0.238	0.193	0.072	0.105	
mc_top-p-ent-0.95	0.276	0.186	0.154	0.232	0.194	0.309	0.178	0.104	0.214	0.050	0.197	0.216	0.112	0.210	0.172	0.388	0.374	0.216	0.207	0.162	0.377	0.173	0.169	0.214	0.177	0.123	0.203	0.097	0.213	0.099	
mc_top-p-ent-0.9	0.282	0.210	0.171	0.230	0.204	0.391	0.194	0.154	0.218	0.080	0.202	0.346	0.130	0.267	0.183	0.560	0.376	0.253	0.218	0.155	0.407	0.284	0.177	0.269	0.178	0.134	0.217	0.170	0.227	0.123	
mc_top-p-ent-0.75	0.244	0.233	0.169	0.254	0.204	0.494	0.183	0.173	0.221	0.291	0.191	0.508	0.134	0.355	0.158	0.703	0.365	0.340	0.193	0.202	0.403	0.369	0.161	0.316	0.162	0.137	0.224	0.179	0.202	0.147	
mc_top-p-ent-0.5	0.190	0.226	0.140	0.325	0.164	0.392	0.160	0.164	0.228	0.514	0.225	0.435	0.152	0.416	0.120	0.590	0.302	0.517	0.156	0.222	0.287	0.499	0.156	0.302	0.133	0.151	0.194	0.180	0.116	0.121	-0.950
	Llama_2_7B	Llama_2_7B_Chat	Llama_2_13B	Llama_2_13B_Chat	Mistral_0.1	Mistral_0.1_Ins	Mistral_0.3	Mistral_0.3_Ins	Falcon3_1B	Falcon3_1B_Ins	Falcon3_3B	Falcon3_3B_Ins	Falcon3_7B	Falcon3_7B_Ins	Falcon3_10B	Falcon3_10B_Ins	Gemma_2B	Gemma_2B_Ins	Gemma_7B	Gemma_7B_Ins	Llama_3.2_1B	Llama_3.2_1B_Ins	Llama_3.2_3B	Llama_3.2_3B_Ins	Llama_3.1_8B	Llama_3.1_8B_Ins	Gemma2_2B	Gemma2_2B_Ins	Gemma2_9B	Gemma2_9B_Ins	Wilcoxon r (IFT Pairs)